Relatório de Laboratório

Laboratório de Experimentação de Software

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor(a)	Danilo Maia
Laboratório	Lab03 - Mineração e análise de métricas DORA
Grupo (trio)	Isabella Dias · Leandro Alencar · Luis Henrique
Link do repositório / GitHub Projects	https://github.com/alencarleandro/DORA
Data de entrega	22/10/2026

1. Introdução

Investigamos como proxies das métricas DORA descrevem a entrega de software em 300 repositórios públicos com GitHub Actions. O estudo usa dados de 2025 e combina estatística descritiva, classificação por faixas, correlações e comparações entre grupos. Releases e falhas de pipeline são sinais indiretos: não observamos deploys e incidentes reais em produção.

A frequência mediana foi 0,46 release por semana e a recuperação observada, 3,77 horas. A correlação entre frequência e falhas muda com a definição de falha; 27,3% dos projetos mudam de categoria entre C1 e C2. Esses resultados mostram por que a definição operacional e o tratamento de dados ausentes precisam acompanhar qualquer interpretação de desempenho.

Estado da entrega: RQ01-RQ07 consolidadas; consenso operacional e calibração concluídos em 20/10/2026. O melhor F1 foi 55,07%, abaixo do mínimo de 70%. O CFR por releases e o retrabalho permanecem exploratórios; a referência assistida não constitui teste independente.

Questões de Pesquisa:

RQ01: Qual é a frequência de releases dos projetos selecionados?

RQ02: Quanto tempo decorre entre commits e releases, nas variantes por release e por commit?

RQ03: Qual é a taxa de falha nos proxies de CI e de entrega?

RQ04: Qual é o tempo de recuperação observado após falhas de workflow?

RQ05: Frequência de releases está associada à taxa de falha?

RQ06: Métricas diferem entre grupos de popularidade, contribuidores e idade?

RQ07: Quanto a categoria DORA muda com a definição operacional?

RQ08: Qual é a proporção de releases corretivas entre todas as releases?

Hipóteses informais: não foi localizado um registro datado anterior à coleta que permita transcrevê-las com segurança. Portanto, não criamos hipóteses retrospectivas nem afirmamos sua confirmação.

2. Contexto

O Lab03 parte da mineração e preparação dos dados nas Sprints 1 e 2 e chega à análise estatística na Sprint 3. A unidade de observação é o repositório. A janela comum é de 01/01 a 31/12/2025, em UTC. Cada projeto tem o mesmo peso nas estatísticas e nos testes. Não agregamos equipes ou organizações como se fossem um único sistema.

As métricas DORA orientam a melhoria do fluxo e da estabilidade de entrega. Neste laboratório, releases publicadas aproximam entregas, runs de CI aproximam falhas internas e correções posteriores aproximam problemas de entrega. Os cortes Elite, High, Medium e Low são os cortes fixos, não uma classificação oficial atual da DORA para esses projetos.

3. Metodologia

3.1 Principais Desafios

A coleta precisou lidar com paginação, teto de resultados por consulta, rate limit, retomada e token inválido. A janela de runs foi subdividida por mês e por intervalos menores quando necessário. Comparações de commits indisponíveis, múltiplas branches e tags de monorepos exigiram rastreabilidade. Na análise, duração negativa, censura e o objetivo ambíguo de releases corretivas impediram o tratamento automático de toda ausência como zero.

3.2 Tomadas de Decisão

Selecionamos projetos com pelo menos 1.001 estrelas, excluindo forks e arquivados, uso observável de Actions, ao menos cinco releases válidas e 50 runs válidos de push na branch principal. Releases draft e prerelease não entram na definição principal. Erros e consultas pendentes permanecem separados das exclusões. A idade é metadado, não um mínimo de inclusão.

A C1 completa exige quatro métricas observadas. A versão com dimensões disponíveis é publicada separadamente, sem imputação. Durações negativas são excluídas apenas da medida afetada. Para a frequência mensal, usamos 12 releases por ano civil, evitando o arredondamento de 52,14 semanas. Quartis seguem interpolação linear tipo 7.

3.3 Etapas

Etapa	Entregas	Responsável(is)
Lab03/Sprint 1	Seleção e metadados #1	Isabella
Lab03/Sprint 1	Releases e commits #2	Luis
Lab03/Sprint 1	Workflows e infraestrutura #3	Leandro
Lab03/Sprint 2	Dataset e dicionário #6	Isabella
Lab03/Sprint 2	Concordância e consenso #4	Luis
Lab03/Sprint 2	Heurística CFR b #5	Leandro
Lab03/Sprint 3	RQ05 e RQ06 #8	Isabella
Lab03/Sprint 2	RQ07 e bônus RQ08 #9	Luis
Lab03/Sprint 2	RQ01–04 e C1 #7	Leandro
Relatório final	Resultados, gráficos e discussão.	Luis, Isabella e Leandro

3.4 Ferramentas

Ferramentas
Cliente próprio REST em Node.js
Python 3.12
NumPy 2.5.4
Pandas 3.0.6
SciPy 1.18.1
GitHub Projects
Statsmodels 0.15.0
Matplotlib 3.11.2

Há testes Node/Python e replicação independente da sensibilidade.

3.5 Tabela de Métricas

RQ	Definição operacional e unidade	Fonte ou método
RQ01	Releases válidas / semanas da janela	GitHub REST; releases/semana

RQ	Definição operacional e unidade	Fonte ou método
RQ02	(a) release - commit mais antigo, depois mediana; (b) mediana de todos os commits por projeto	Compare API / histórico Git; horas
RQ03	R(a) falhas/(falhas+sucessos); (b) release seguida de corretiva em ≤7 dias	Runs e heurística; proporção
RQ04	Próximo sucesso - primeira falha após sucesso, no mesmo workflow	Runs; horas; censura explícita
RQ05	Spearman bilateral em frequência × cada CFR	ρ, p assintótico e permutação
RQ06	Três fatores × seis medidas; Holm nos 18 testes	Kruskal–Wallis; $\varepsilon^2=H/(n-1)$
RQ07	Mudança de categoria e kappa linear ponderado	C1-C4; quatro notas e mediana
RQ08	Releases corretivas / total de releases válidas	válidas Heurística; razão exploratória

3.6 Inovações Propostas pelo Grupo

Além das análises principais, o pipeline mantém dados persistentes e permite executar B e C localmente a partir de A, sem novo token. Publicamos classificação estrita de casos completos e uma extensão para dados parciais, acompanhadas de testes de integração e hashes. Na RQ05, uma permutação bilateral Monte Carlo com 9.999 repetições e sementes 42/43 complementa o p assintótico. Essas extensões não substituem os requisitos principais nem comprovam, por si, a parcela de inovação prevista no template.

O bônus de retrabalho é tratado como RQ08, e não como uma pergunta inédita. Para essa sprint final, corrigimos sua definição: contar releases que recebem uma correção posterior não é o mesmo que contar as releases corretivas. A Figura 10 usa a segunda contagem, recalculada dos dados brutos locais, e preserva dois casos desconhecidos.

4. Resultados

4.1 Coleta de Dados

O orçamento reuniu 1.100 candidatos únicos. O funil registra 917 com Actions e 88 consultas pendentes nessa etapa; 95 foram excluídos por esse critério. Após releases e runs, 302 eram elegíveis e 300 foram selecionados, com dois fora do limite. Pendência não foi contada como exclusão nem como ausência de atividade.

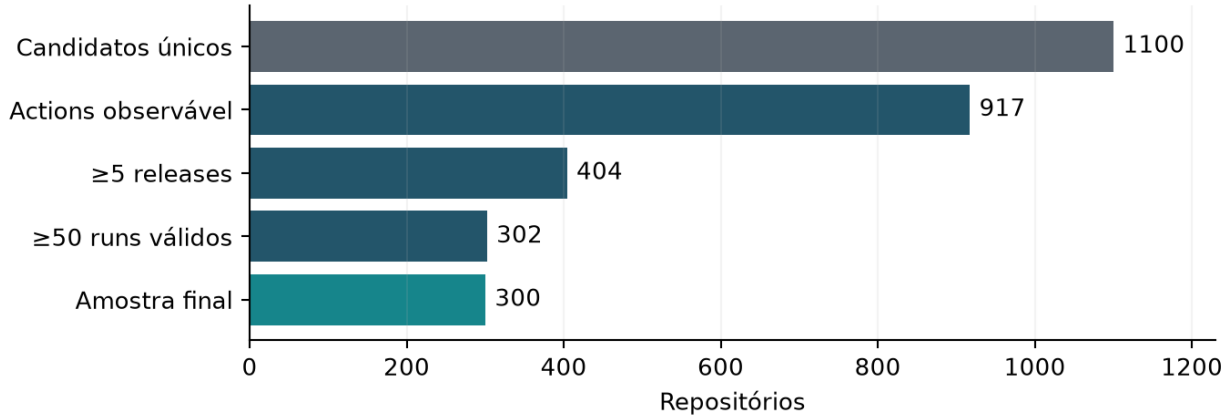


Figura 1. Funil de seleção. Na etapa de Actions, há 88 pendentes além dos 95 excluídos; as barras mostram somente quem segue. Fonte: selecao/funnel.csv.

As duas definições de CFR e o lead time por release têm n=300; lead time por commit, n=299, após excluir o negativo de tw93/Mole. Recuperação tem n=258: 37 projetos sem episódio e cinco apenas com episódios censurados. Há duas comparações de commits indisponíveis no inventário; o dataset mantém valores ausentes, em vez de inventar zeros.

A amostra-ouro reúne 60 projetos × cinco releases, sorteados com semente 42 entre 299 projetos com comparações disponíveis. O consenso operacional chegou à seguinte conclusão: 112 corretivas, 188 não corretivas; melhor F1=55,07%.

4.2 Visualização Gráfica

RQ01 - Qual é a frequência de releases?

A mediana é 0,46 release/semana, Q1=0,23 e Q3=1,00 (IQR=0,77; n=300). A distribuição é assimétrica: poucos projetos têm cadência muito superior ao centro da amostra.

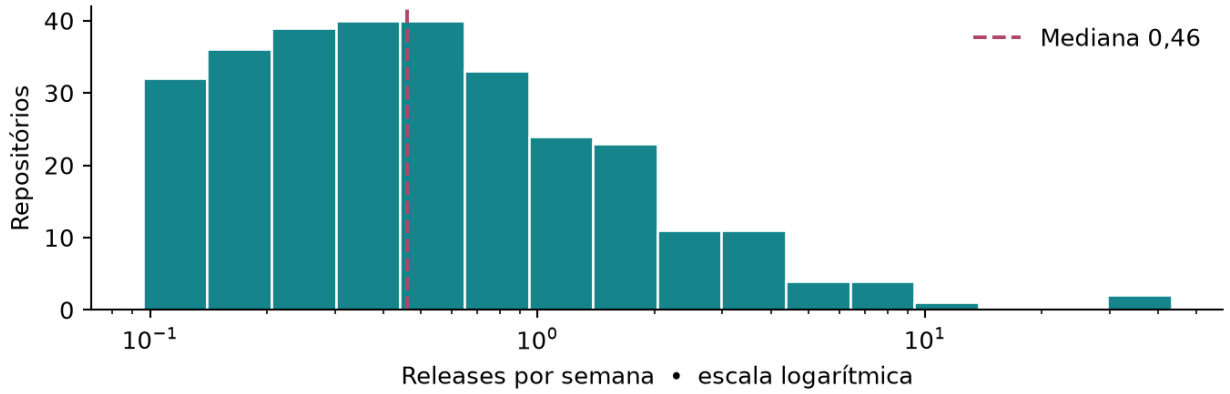


Figura 2. Histograma da frequência com bins e eixo logarítmicos; a linha marca a mediana. Cada projeto contribui uma observação.

RQ02 - Como diferem os dois lead times?

A mediana das medianas por release é 325,37 h (IQR=989,67; n=300); por commit, 428,62 h (IQR=1.738,16; n=299). A diferença entre as duas medianas marginais não representa uma diferença pareada universal: os pesos das releases e dos commits são distintos.

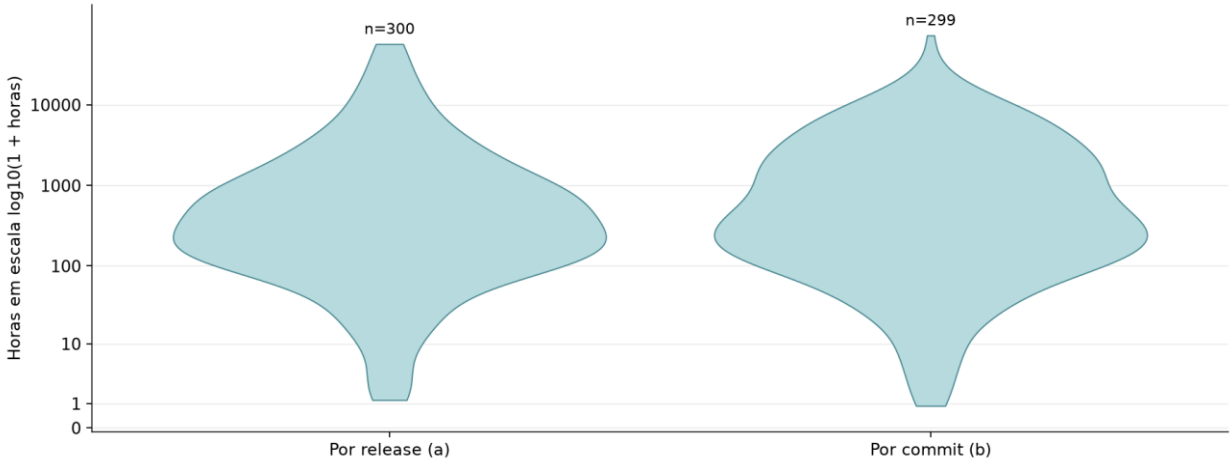


Figura 3. Violinos das medianas por projeto. Densidade estimada em log10(1+horas); eixo rotulado em horas. A largura suavizada indica concentração, não contagem exata nem valores negativos.

RQ03 - Qual é a taxa de falha nos dois proxies?

O CFR de CI tem mediana 5,64% (IQR=12,18 pontos percentuais). O proxy de entrega tem mediana 25,00% (IQR=42,36 pontos), ambos n=300. O segundo resultado é exploratório, porque a heurística não foi validada contra o consenso final. Falha de CI não é considerada como incidente de produção.

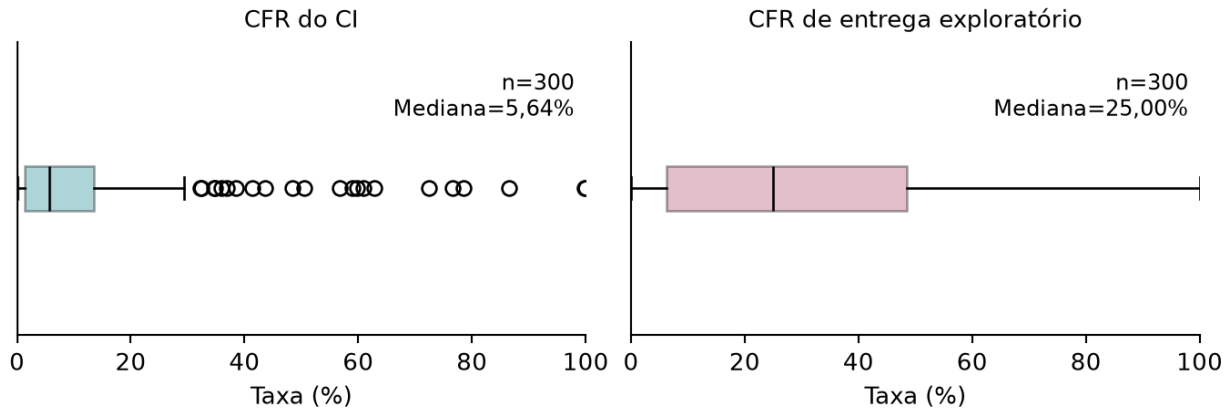


Figura 4. Boxplots de CFR por projeto, com mediana, quartis e pontos além dos bigodes. A escala comum permite comparar os proxies sem assumir que medem o mesmo fenômeno.

RQ04 - Quanto tempo demora a recuperação observada?

A mediana é 3,77 h, com Q1=1,44 h e Q3=12,56 h (IQR=11,13 h; n=258). A fração censurada tem mediana zero entre 263 projetos com denominador. Mediana zero de censura não significa ausência de episódios censurados em toda a coorte.

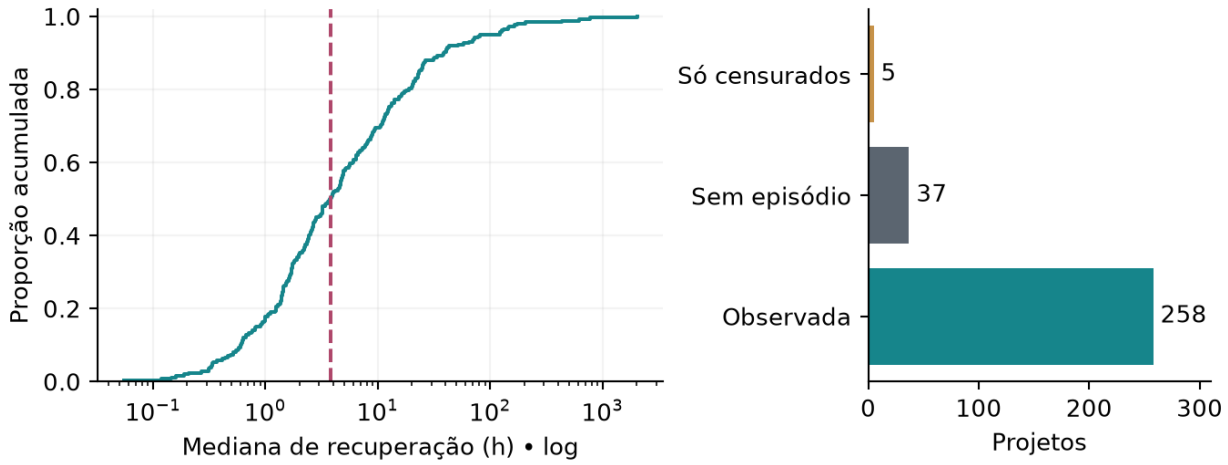


Figura 5. ECDF das medianas observadas e barras de cobertura. Os 42 casos sem recuperação observada não recebem duração zero. A ECDF descreve somente episódios com recuperação concluída, não uma estimativa de sobrevivência.

RQ05 - Frequência de releases está associada à taxa de falha?

Para CI, ρ=0,064, p=0,2708 e p de permutação=0,2718 (n=300): não detectamos associação monotônica a 5%. Para entrega, ρ=0,571, p<0,0001 e p de permutação=0,0001 (n=300): há associação positiva, ainda exploratória pela falta de validação do proxy.

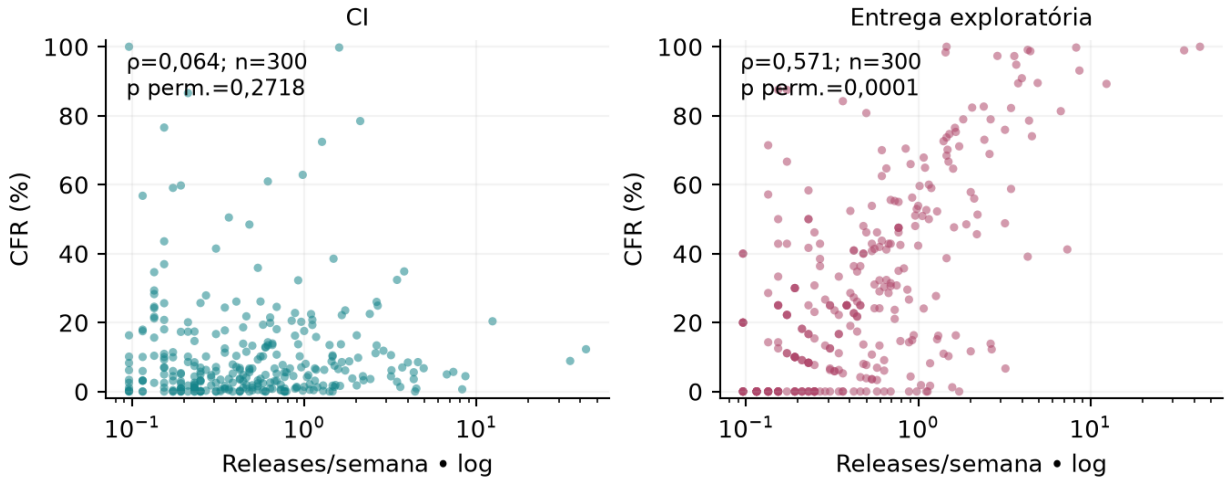


Figura 6. Dispersões dos dois proxies contra frequência em escala logarítmica. As sementes são 42 e 43; p Monte Carlo tem resolução mínima 0,0001. A correlação não demonstra que publicar mais causa falhas.

RQ06 - Quais características estão associadas a diferenças nas métricas?

Dividimos estrelas, contribuidores e idade em quartis, definidos antes de filtrar cada medida. Os três fatores têm 75 projetos por grupo antes das exclusões. Todos os 18 testes foram estimáveis; oito rejeitaram igualdade de distribuições após Holm, α=0,05. Não fizemos post-hoc: o teste global não identifica sozinho quais pares diferem.

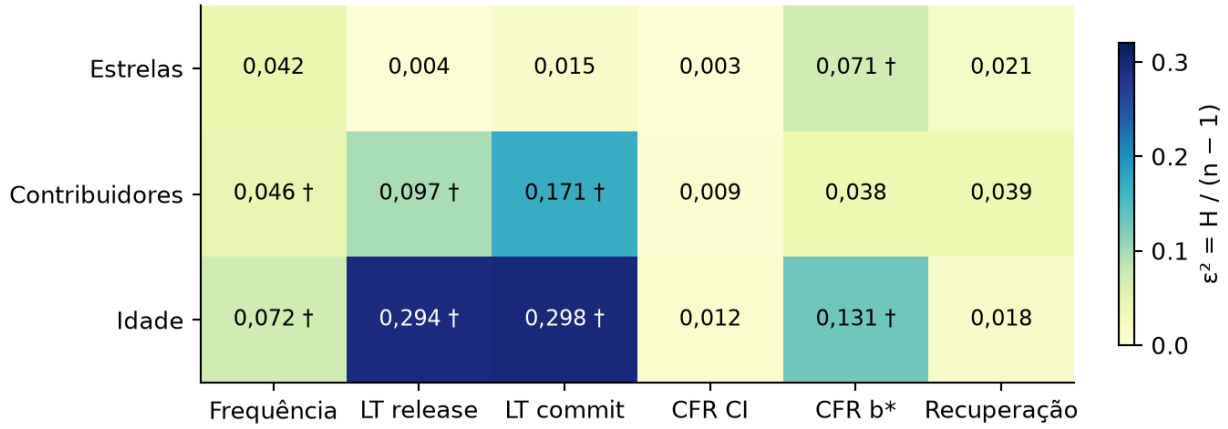


Figura 7. Tamanho de efeito ε²=H/(n−1) nos 18 testes. † indica p de Holm<0,05. CFR b* é exploratório. Cor mostra magnitude de associação, sem interpretação causal e sem transpor cortes de Cliff's delta para ε².

RQ06 - Como o lead time varia entre quartis de idade?

Idade apresenta os maiores efeitos nos lead times: ε^2=0,294 por release e 0,298 por commit, com p de Holm<0,0001. Contribuidores apresenta ε^2=0,097 e 0,171 nessas variantes. Não houve rejeição após Holm para CFR de CI ou recuperação em nenhum dos três fatores.

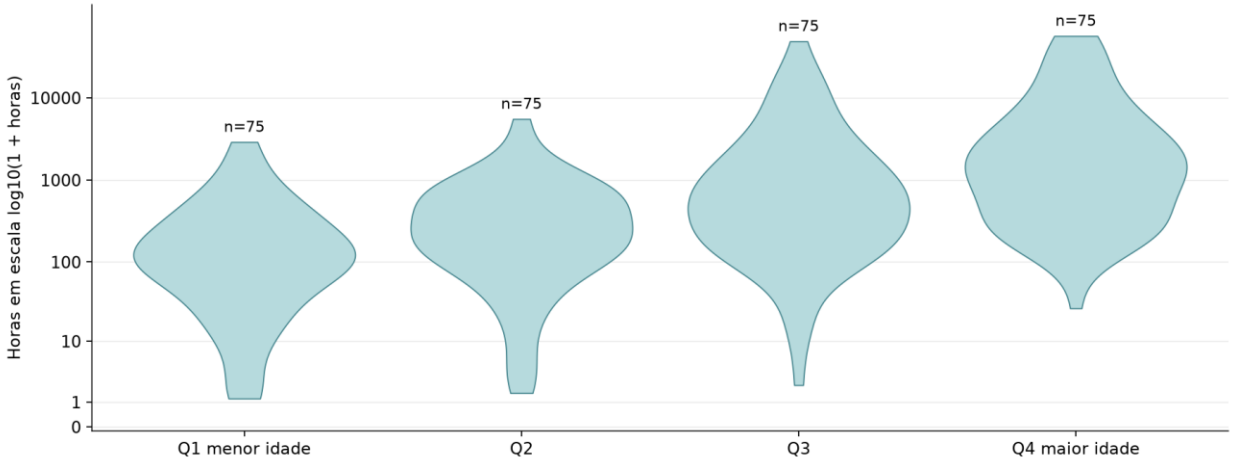


Figura 8. Lead time por release entre quartis de idade, com gráficos de violino. Densidade estimada na transformação log10(1+horas); grupos têm n=75. A idade é associada à distribuição, não uma causa demonstrada do lead time.

RQ07 - Quanto a categoria muda ao trocar a definição operacional?

C1 usa lead time por release e CFR de CI; C2 usa lead time por commit e CFR de entrega. C3 troca só o CFR e C4, só o lead time. Frequência e recuperação são mantidas. Entre C1 e C2, 82/300 mudam de categoria (27,3%): 18 sobem e 64 descem; κ linear=0,5745. A C1 completa tem 258 projetos: 15 Low, 132 Medium, 103 High e oito Elite.

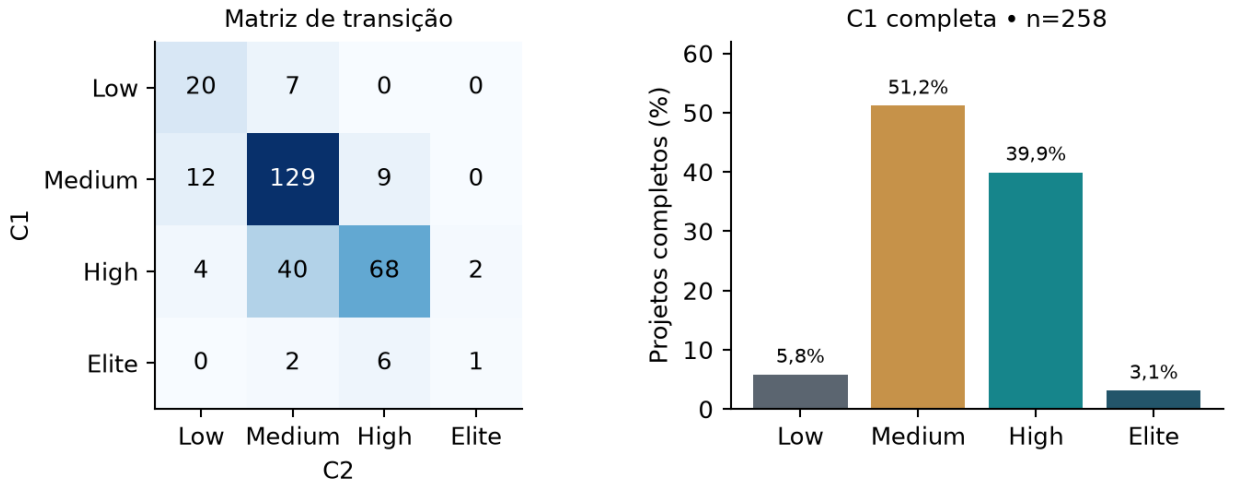


Figura 9. Matriz de C1 para C2 nos 300 projetos com dimensões disponíveis; barras da C1 completa nos 258 casos. Políticas distintas de cobertura não devem ser confundidas. A réplica Python conferiu os seis kappas com tolerância de 10^{-9}.

RQ08 - Qual é a proporção de releases corretivas?

Recontamos as releases classificadas como corretivas pela heurística fix-majority-v3, sem usar o número de releases que falharam como numerador. Nos 299 projetos sem comparações desconhecidas, a mediana é 60,00%, com Q1=22,90% e Q3=85,60%. Um projeto tem duas comparações desconhecidas e fica fora dessa estatística pontual, com intervalo mínimo/máximo registrado no artefato de apoio.

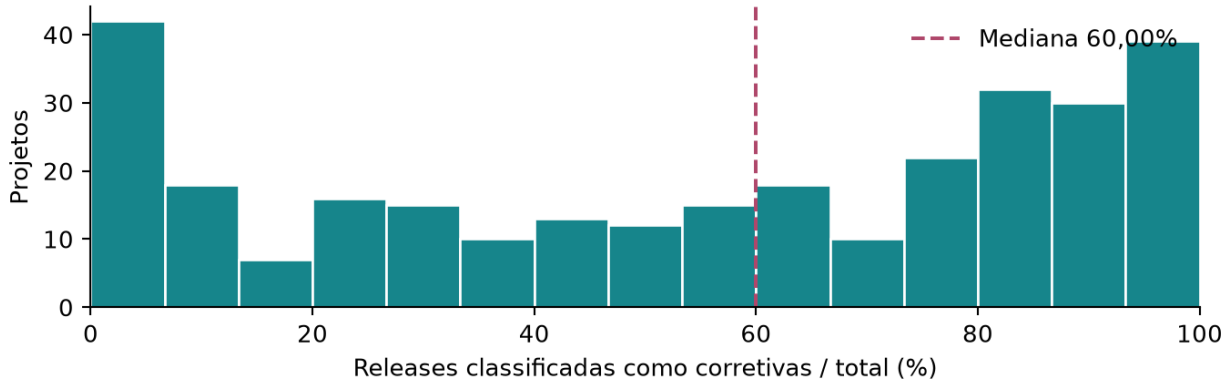


Figura 10. Histograma exploratório da proporção de releases corretivas (n=299). Esta medida difere da anterior failed/total: uma release que corrige e uma release que precisou de correção são observações distintas. Sem F1, não constitui mensuração validada de retrabalho em produção.

4.3 Discussão

A baixa associação entre frequência e falhas do CI e a associação positiva no proxy de entrega impedem uma resposta única sobre velocidade versus estabilidade. A regra “corretiva em até sete dias” também pode tornar a frequência mecanicamente relacionada ao proxy de falha: há mais oportunidades de encontrar uma release próxima. O resultado não demonstra um trade-off causal nem refuta diretamente a pesquisa DORA sobre sistemas em produção.

A sensibilidade de categorias confirma a importância das definições operacionais. Ela não prova que as correlações ou os testes de grupos sejam robustos a todas as variantes; isso exigiria repetir cada análise. A idade e o número de contribuidores se associam aos lead times, mas podem representar maturidade, tamanho e práticas não observadas.

Não comparamos hipóteses a priori ausentes como se estivessem registradas. A extensão por permutação conserva o resultado qualitativo das correlações. A separação de C1 completa/parcial e o registro dos casos ambíguos expõem incertezas que seriam escondidas por imputação zero ou pelo uso de métricas sem validação.

5. Conclusão

Nesta coorte de 300 repositórios populares, os dados descrevem cadências e durações muito assimétricas e resultados sensíveis à forma de medir. As RQ01–04 fornecem a referência descritiva; RQ05 não detectou associação entre frequência e CFR de CI, enquanto encontrou associação no proxy exploratório de entrega. Na RQ06, oito dos 18

testes permaneceram significativos após Holm, principalmente para lead time, idade e contribuidores. A RQ07 mostrou mudança de faixa em mais de um quarto da amostra entre duas definições.

As limitações centrais são o uso de proxies, seleção de projetos populares, retenção e disponibilidade do histórico, fotografias de metadados obtidas após a janela, diferentes pesos de agregação, dados censurados e falta de validação do classificador corretivo. A RQ08 foi recontada com o numerador correto, mas permanece exploratória.

6. Referências

DORA. Software delivery performance metrics. Atualização de 05 jan. 2026. https://dora.dev/guides/dora-metrics/ (acesso em 18 out. 2026).

FORSGREN, N.; HUMBLE, J.; KIM, G. Accelerate. IT Revolution, 2018.

SciPy. spearmanr e kruskal. Documentação de scipy.stats. https://docs.scipy.org/doc/scipy/reference/stats.html.

Statsmodels. multipletests e correção de Holm. https://www.statsmodels.org/stable/generated/statsmodels.stats.multitest.multipletests.html.

HYNDMAN, R. J.; FAN, Y. Sample quantiles in statistical packages. The American Statistician, v. 50, n. 4, p. 361–365, 1996.