1. Introdução

Investigamos como proxies das métricas DORA descrevem a entrega de software em 300 repositórios públicos com GitHub Actions. O estudo usa dados de 2025 e combina estatística descritiva, classificação por faixas, correlações e comparações entre grupos. Releases e falhas de pipeline são sinais indiretos: não observamos deploys e incidentes reais em produção.

A frequência mediana foi 0,46 release por semana e a recuperação observada, 3,77 horas. A correlação entre frequência e falhas muda com a definição de falha; 27,3% dos projetos mudam de categoria entre C1 e C2. Esses resultados mostram por que a definição operacional e o tratamento de dados ausentes precisam acompanhar qualquer interpretação de desempenho.

Estado da entrega: RQ01-RQ07 consolidadas; consenso operacional e calibração concluídos em 20/10/2026. O melhor F1 foi 55,07%, abaixo do mínimo de 70%. O CFR por releases e o retrabalho permanecem exploratórios; a referência assistida não constitui teste independente.

Questões de Pesquisa:

RQ01: Qual é a frequência de releases dos projetos selecionados?

RQ02: Quanto tempo decorre entre commits e releases, nas variantes por release e por commit?

RQ03: Qual é a taxa de falha nos proxies de CI e de entrega?

RQ04: Qual é o tempo de recuperação observado após falhas de workflow?

RQ05: Frequência de releases está associada à taxa de falha?

RQ06: Métricas diferem entre grupos de popularidade, contribuidores e idade?

RQ07: Quanto a categoria DORA muda com a definição operacional?

RQ08: Qual é a proporção de releases corretivas entre todas as releases?

O bônus de retrabalho é tratado como RQ08, e não como uma pergunta inédita. Para essa sprint final, corrigimos sua definição: contar releases que recebem uma correção posterior não é o mesmo que contar as releases corretivas. A Figura 10 usa a segunda contagem, recalculada dos dados brutos locais, e preserva dois casos desconhecidos.

4. Resultados

4.1 Coleta de Dados

O orçamento reuniu 1.100 candidatos únicos. O funil registra 917 com Actions e 88 consultas pendentes nessa etapa; 95 foram excluídos por esse critério. Após releases e runs, 302 eram elegíveis e 300 foram selecionados, com dois fora do limite. Pendência não foi contada como exclusão nem como ausência de atividade.

Figura 1

Figura 1. Funil de seleção. Na etapa de Actions, há 88 pendentes além dos 95 excluídos; as barras mostram somente quem segue. Fonte: selecao/funnel.csv.

As duas definições de CFR e o lead time por release têm n=300; lead time por commit, n=299, após excluir o negativo de tw93/Mole. Recuperação tem n=258: 37 projetos sem episódio e cinco apenas com episódios censurados. Há duas comparações de commits indisponíveis no inventário; o dataset mantém valores ausentes, em vez de inventar zeros.

A amostra-ouro reúne 60 projetos × cinco releases, sorteados com **semente 42** entre 299 projetos com comparações disponíveis. Os três arquivos oficiais estão preenchidos. O consenso operacional e a calibração foram concluídos: **112 corretivas, 188 não corretivas; melhor F1=55,07%**. O procedimento e seus limites estão no Apêndice A (página 10).

4.2 Visualização Gráfica

RQ01 - Qual é a frequência de releases?

A mediana é 0,46 release/semana, Q1=0,23 e Q3=1,00 (IQR=0,77; n=300). A distribuição é assimétrica: poucos projetos têm cadência muito superior ao centro da amostra.

Figura 2

Figura 2. Histograma da frequência com bins e eixo logarítmicos; a linha marca a mediana. Cada projeto contribui uma observação.

RQ02 - Como diferem os dois lead times?

A mediana das medianas por release é 325,37 h (IQR=989,67; n=300); por commit, 428,62 h (IQR=1.738,16; n=299). A diferença entre as duas medianas marginais não representa uma diferença pareada universal: os pesos das releases e dos commits são distintos.

Figura 3

Figura 3. Violinos e boxplots das medianas por projeto. Densidade estimada em log10(1+horas); eixo rotulado em horas. A largura suavizada indica concentração, não contagem exata nem valores negativos.

RQ03 - Qual é a taxa de falha nos dois proxies?

O CFR de CI tem mediana 5,64% (IQR=12,18 pontos percentuais). O proxy de entrega tem mediana 25,00% (IQR=42,36 pontos), ambos n=300. O segundo resultado permanece exploratório: a calibração no consenso operacional teve F1=55,07%, abaixo do mínimo de 70% (Apêndice A). Falha de CI não é considerada incidente de produção.

Figura 4

Figura 4. Boxplots de CFR por projeto, com mediana, quartis e pontos além dos bigodes. A escala comum permite comparar os proxies sem assumir que medem o mesmo fenômeno.

RQ04 - Quanto tempo demora a recuperação observada?

A mediana é 3,77 h, com Q1=1,44 h e Q3=12,56 h (IQR=11,13 h; n=258). A fração censurada tem mediana zero entre 263 projetos com denominador. Mediana zero de censura não significa ausência de episódios censurados em toda a coorte.

Figura 5

Figura 5. ECDF das medianas observadas e barras de cobertura. Os 42 casos sem recuperação observada não recebem duração zero. A ECDF descreve somente episódios com recuperação concluída, não uma estimativa de sobrevivência.

RQ05 - Frequência de releases está associada à taxa de falha?

Para CI, ρ=0,064, p=0,2708 e p de permutação=0,2718 (n=300): não detectamos associação monotônica a 5%. Para entrega, ρ=0,571, p<0,0001 e p de permutação=0,0001 (n=300): há associação positiva, ainda exploratória diante do F1 insuficiente e das limitações de independência da referência de calibração.

Figura 6

Figura 6. Dispersões dos dois proxies contra frequência em escala logarítmica. As sementes são 42 e 43; p Monte Carlo tem resolução mínima 0,0001. A correlação não demonstra que publicar mais causa falhas.

RQ06 - Quais características estão associadas a diferenças nas métricas?

Dividimos estrelas, contribuidores e idade em quartis, definidos antes de filtrar cada medida. Os três fatores têm 75 projetos por grupo antes das exclusões. Todos os 18 testes foram estimáveis; oito rejeitaram igualdade de distribuições após Holm, α=0,05. Não fizemos post-hoc: o teste global não identifica sozinho quais pares diferem.

Figura 7

Figura 7. Tamanho de efeito $\varepsilon^2=H/(n-1)$ nos 18 testes. † indica p de Holm<0,05. CFR b* é exploratório. Cor mostra magnitude de associação, sem interpretação causal e sem transpor cortes de Cliff's delta para ε^2.

RQ06 - Como o lead time varia entre quartis de idade?

Idade apresenta os maiores efeitos nos lead times: ε^2=0,294 por release e 0,298 por commit, com p de Holm<0,0001. Contribuidores apresenta ε^2=0,097 e 0,171 nessas variantes. Não houve rejeição após Holm para CFR de CI ou recuperação em nenhum dos três fatores.

Figura 8

Figura 8. Lead time por release entre quartis de idade, com violinos e boxplots. Densidade estimada na transformação log10(1+horas); grupos têm n=75. A idade é associada à distribuição, não uma causa demonstrada do lead time.

RQ07 - Quanto a categoria muda ao trocar a definição operacional?

C1 usa lead time por release e CFR de CI; C2 usa lead time por commit e CFR de entrega. C3 troca só o CFR e C4, só o lead time. Frequência e recuperação são mantidas. Entre C1 e C2, 82/300 mudam de categoria (27,3%): 18 sobem e 64 descem; κ linear=0,5745. A C1 completa tem 258 projetos: 15 Low, 132 Medium, 103 High e oito Elite.

Figura 9

Figura 9. Matriz de C1 para C2 nos 300 projetos com dimensões disponíveis; barras da C1 completa nos 258 casos. Políticas distintas de cobertura não devem ser confundidas. A réplica Python conferiu os seis kappas com tolerância de 10^{-9}.

RQ08 - Qual é a proporção de releases corretivas?

Recontamos as releases classificadas como corretivas pela heurística fix-majority-v3, sem usar o número de releases que falharam como numerador. Nos 299 projetos sem comparações desconhecidas, a mediana é 60,00%, com Q1=22,90% e Q3=85,60%. Um projeto tem duas comparações desconhecidas e fica fora dessa estatística pontual, com intervalo mínimo/máximo registrado no artefato de apoio.

Figura 10

Figura 10. Histograma exploratório da proporção de releases corretivas (n=299). Esta medida difere de failed/total: corrigir uma release e precisar de correção são observações distintas. Com F1=55,07%, abaixo do mínimo de 70%, não constitui mensuração validada de retrabalho em produção.

4.3 Discussão

As associações distintas nos proxies de CI e entrega impedem uma resposta única sobre velocidade versus estabilidade. A regra “corretiva em até sete dias” pode relacionar mecanicamente frequência e falha: mais releases oferecem mais oportunidades de correção próxima. Não se demonstra um trade-off causal nem se refuta diretamente a pesquisa DORA sobre produção.

A sensibilidade confirma a importância das definições operacionais, mas não prova robustez das correlações e testes a todas as variantes; seria preciso repeti-los. Idade e contribuidores podem representar maturidade, tamanho e práticas não observadas.

A calibração quantifica uma limitação central: 88 falsos positivos e 36 falsos negativos em 300 referências. Embora a concordância corretiva tenha κ=0,9321, a origem comum das sugestões de IA impede tratá-la como evidência de confiabilidade humana independente. O consenso operacional não demonstra que o proxy represente incidentes reais em produção.

Não comparamos hipóteses a priori ausentes como se estivessem registradas. A extensão por permutação conserva o resultado qualitativo das correlações. A separação de C1 completa/parcial e o registro dos casos ambíguos expõem incertezas que seriam escondidas por imputação zero ou pelo uso de métricas sem validação suficiente.

5. Conclusão

Nesta coorte de 300 repositórios populares, os dados descrevem cadências e durações muito assimétricas e resultados sensíveis à forma de medir. As RQ01-04 fornecem a referência descritiva; RQ05 não detectou associação entre frequência e CFR de CI, enquanto encontrou associação no proxy exploratório de entrega. Na RQ06, oito dos 18 testes permaneceram significativos após Holm, principalmente para lead time, idade e contribuidores. A RQ07 mostrou mudança de faixa em mais de um quarto da amostra entre duas definições.

O consenso operacional e a calibração foram concluídos: a melhor heurística teve precisão de 46,34%, recall de 67,86% e F1 de 55,07%, abaixo do mínimo de 70%. Assim, o CFR (b) e a RQ08 permanecem exploratórios. O uso de proxies, a seleção de projetos populares, a disponibilidade do histórico, metadados posteriores à janela, pesos de agregação, censura e a origem compartilhada das sugestões limitam a interpretação. As faixas da disciplina não autorizam ranquear organizações ou inferir falhas reais em produção.

Para a entrega definitiva, ainda é necessário recuperar o registro de hipóteses, confirmar a política de WIP e anexar a captura do Projects. A heurística exige revisão e avaliação adequada, idealmente independente. Se a regra mudar, devem ser recalculados os resultados dependentes. Não alteramos os rótulos para atingir o corte de F1. A análise descritiva pode ser reproduzida sem novo token; a recontagem RQ08 requer os arquivos brutos de releases.

6. Referências

DORA. Software delivery performance metrics. Atualização de 05 jan. 2026. https://dora.dev/guides/dora-metrics/ (acesso em 18 out. 2026).

FORSGREN, N.; HUMBLE, J.; KIM, G. Accelerate. IT Revolution, 2018.

SciPy. spearmanr e kruskal. Documentação de scipy.stats. https://docs.scipy.org/doc/scipy/reference/stats.html.

Statsmodels. multipletests e correção de Holm. https://www.statsmodels.org/stable/generated/statsmodels.stats.multitest.multipletests.html.

HYNDMAN, R. J.; FAN, Y. Sample quantiles in statistical packages. The American Statistician, v. 50, n. 4, p. 361-365, 1996.

Equipe DORA. Consenso operacional e calibração CFR (b), 20 out. 2026. Repositório alencarleandro/DORA: data/gold-standard-final-300-2025/ e data/dataset-s02-final/validacao/cfr-b/.

Apêndice A - Consenso e calibração do CFR (b)

Em 20/10/2026, os três arquivos oficiais da amostra final continham 300 classificações cada. As 300 referências foram conferidas contra tags e datas reais da janela de 01/01 a 31/12/2025. A concordância abaixo foi medida **antes da adjudicação**, preservando as respostas individuais.

Dimensão	N	Concordância observada	κ de Fleiss
Tipo de projeto	60	96,67%	0,9490
Entrega real	60	95,56%	0,4055
Release corretiva	300	96,89%	0,9321

Foram identificadas divergências em **14 releases** quanto à finalidade corretiva e em **7 projetos** quanto a tipo ou entrega real. O grupo autorizou o assistente a adjudicar esses casos pelas notas, commits e evidências salvas. O consenso operacional resultou em **112 corretivas e 188 não corretivas**; os 286 rótulos corretivos unânimes foram mantidos.

Limite metodológico: Luis e Leandro partiram de sugestões de IA comuns, posteriormente revisadas e aceitas conforme registrado. Por isso, a concordância não demonstra independência de três avaliadores humanos. As divergências foram resolvidas por adjudicação de IA delegada, com justificativas registradas, sem afirmar discussão humana por item.

Desempenho das três versões na referência operacional

Versão	TP	FP	FN	TN	Precisão	Recall	F1
patch-v1	65	72	47	116	47,45%	58,04%	52,21%
patch-or-fix-v2	106	178	6	10	37,32%	94,64%	53,54%
fix-majority-v3	76	88	36	100	46,34%	67,86%	55,07%

A melhor versão foi **fix-majority-v3**: precisão de **46,34%**, recall de **67,86%** e F1 de **55,07%**. Sua matriz tem 76 verdadeiros positivos, 88 falsos positivos, 36 falsos negativos e 100 verdadeiros negativos. O F1 **não atingiu o mínimo de 70%**; a heurística não foi aprovada.

Precisão = TP/(TP+FP); recall = TP/(TP+FN); F1 = 2TP/(2TP+FP+FN). Selecionar a melhor versão no mesmo consenso é **calibração, não teste independente**. Os valores do dataset e as análises anteriores não foram recalculados: a versão já utilizada continuou sendo a melhor, mas seu desempenho insuficiente mantém exploratórios o CFR (b) e a RQ08.

Rastreabilidade: data/gold-standard-final-300-2025/consensus.csv, adjudication-log.json e agreement_report.json; data/dataset-s02-final/validacao/cfr-b/validation.json e heuristic-versions.csv. As matrizes foram recontadas a partir das previsões e os 19 testes de concordância e heurística passaram.